

機械学習による画像分類のキホン: 初心者向け徹底ガイド

1. はじめに

機械学習と画像分類への招待

私たちの周りには、スマートフォンで撮った写真、インターネットで見かける画像、監視カメラの映像など、数えきれないほどの画像があふれています。もしコンピュータが、これらの画像を見て、そこに写っているものが何かを「理解」できたら、どれほど便利になるでしょうか？例えば、大量の写真を自動で整理したり、製品の欠陥を見つけたり、病気の兆候を発見したりすることが可能になります。このガイドでは、コンピュータが画像の内容を自動で見分ける技術、すなわち「画像分類」の世界を探求します。特に、コンピュータがデータから学ぶ「機械学習」という考え方をを用いて、画像分類がどのように実現されるのかを、初心者の方にも分かりやすく解説していきます。「AI」や「機械学習」と聞くと、難しそうな数式やプログラミングを想像するかもしれませんが、その基本的な考え方は意外とシンプルです。このガイドを通じて、画像分類の基礎を一緒に楽しく学んでいきましょう。

このガイドで学べること

このガイドを読むことで、以下の点が理解できるようになります。

- 画像分類が**「何」をする技術で、「なぜ」**様々な場面で使われているのか。
- コンピュータがデータから**「学ぶ」**とは、具体的にどのようなプロセスなのか。
- 画像分類が実際にどのように行われるのか、その具体的なステップ。
- 画像分類を理解する上で知っておくと便利なキーワードの意味。
- 画像認識で特によく使われる**「CNN」**という技術の基本的な仕組み。
- 画像分類が私たちの実社会でどのように役立っているかの具体例。
- 画像分類を行う上で考慮すべき難しさや注意点。

2. 画像分類ってなんだろう？

定義: コンピュータは画像をどう「見る」のか

画像分類とは、コンピュータに画像データを入力し、その画像全体が「何」を表しているのかを、あらかじめ定義されたカテゴリー（分類項目、クラスとも呼ばれます）の中から判断させる技術です¹。例えば、ある画像を見せて、「これは犬の写真」「これは猫の写真」「これは自動車の写真」といったように、画像の内容を一つのラベル（名前）で言い当てることを目指します¹。

では、コンピュータは画像をどのように「見ている」のでしょうか？人間のようには直感的に全体を捉えるのではなく、コンピュータは画像を非常に小さな色の点（ピクセル）の集まりとして認識します²。各ピクセルは、赤(R)、緑(G)、青(B)などの色の強さを示す数値情報を持っています。コンピュータは、こ

の膨大な数値の羅列を解析することで、画像の中に存在するパターン、例えば線の形状、色の分布、模様(テクスチャ)などを検出し、それらが何を表しているのかを理解しようと試みます²。具体的な例を挙げると、「写真に写っている麺類が『そうめん』なのか『冷やし中華』なのかを判断したい」⁸、「写真に一つだけ写っている部品が『良品』なのか『不良品』なのかを見分けたい」⁸、「監視カメラに写った動物が『イノシシ』『くま』『ねずみ』のどれなのかを知りたい」⁸といった課題を解決するために、画像分類技術が利用されます。

目的:なぜ画像を分類するの？

画像分類の主な目的は、画像の内容を自動的に理解し、それに基づいて情報を整理したり、特定の判断を下したりすることです¹。これにより、人間が行うには時間や手間がかかりすぎる作業を効率化したり、人間では気づきにくいパターンを発見したりすることが可能になります。

具体的な活用目的としては、以下のようなものが挙げられます。

- 情報の整理・検索: 大量の画像データをカテゴリー別に自動で分類し、管理しやすくする(例: スマートフォンの写真フォルダ整理、ECサイトの商品カテゴリ分類³)。また、画像の内容に基づいて関連画像を検索する(例: Google画像検索のような機能²)。
- 状態の判定・検査: 画像に写っている対象の状態を判断する(例: 工場の製造ラインで製品が良品か不良品かを自動で検査する³、医療画像から病変の有無を検出する支援²)。
- 識別の自動化: 特定の対象を識別するプロセスを自動化する(例: 空港での顔認証による本人確認¹⁰)。

画像分類 vs 物体検出:何が違う？

画像分類とよく似た技術に「物体検出(Object Detection)」があります。どちらも画像の内容を認識する技術ですが、その目的と出力が異なります。この違いを理解することは、それぞれの技術がどのような場面で使われるかを把握する上で重要です。

| 特徴 | 画像分類 (Image Classification) | 物体検出 (Object Detection) |
|---------|-----------------------------------|--|
| 主な目的 | 画像全体が何を表しているかを判断する ¹ 。 | 画像の中のどこに (Where) 何が (What) あるかを特定する ⁸ 。 |
| 出力例 | 単一のラベル(例:「猫」) ¹ | 物体の位置(例:境界線ボックス)とラベルの組み合わせ(例:「猫(座標A), 犬(座標B)」) ¹⁷ |
| 使われる場面例 | 写真の自動整理、コンテンツフィルタリング、基本的な製品検査 | 自動運転での歩行者・車両検知、監視カメラでの特定物体追跡、より詳細な在庫管理 |

この表からわかるように、画像分類は画像全体の主題、つまり「What」に答える技術です¹。一方、物体検出は画像内に存在する個々の物体の種類「What」とその位置「Where」の両方を特定します⁸。例えば、写真アルバムを「風景」「食べ物」「動物」に分けるなら画像分類が適していますが、自動運転車が前方の歩行者や他の車を避けるためには、それらが画像のどこにあるかを知る必要があります²。この基本的な違いを理解しておくことで、後述する応用例や技術(CNNなど)がどのような文脈で使われているかをより正確に捉えることができます。

3. 機械学習のキホン: データから「学ぶ」ってどういうこと？

コンピュータが経験から学ぶ仕組み

画像分類を実現する上で中心的な役割を果たすのが「機械学習 (Machine Learning)」という技術です。機械学習とは、人間がプログラムを通じてコンピュータに一つ一つの動作ルールを細かく指示する(これはルールベースと呼ばれます²³)のとは異なり、コンピュータ自身が大量のデータ(これを「経験」と捉えることができます)を分析し、その中に潜むパターンや規則性を自動的に「学習」するアプローチです²⁴。

コンピュータは、与えられたデータセットを繰り返し処理することで、データ間の隠れた関係性や特徴を見つけ出します²³。そして、その学習結果を「モデル」と呼ばれる一種の知識体系として構築します。この学習済みモデルを用いることで、コンピュータは過去に見たことのない新しいデータに対しても、学習した知識に基づいて適切な予測や判断を下すことができるようになります²³。

機械学習の大きな特徴は、データ駆動型であることです²⁵。つまり、学習に使うデータの量と質が、最終的なモデルの性能を大きく左右します²⁵。一般的に、より多くの、そしてより質の高いデータを使って学習させるほど、モデルは賢くなり、より正確で信頼性の高い予測や判断が可能になります²⁵。

この「データからルールを自動的に見つけ出す」という機械学習のアプローチは、従来のプログラミング手法と根本的に異なります。従来のプログラミングでは、人間が問題解決のためのルールを事前に定義し、それをコードとして記述する必要がありました²³。しかし、例えば「画像に写っているものが犬である」というルールを、あらゆる犬種、角度、照明条件などを網羅するように人間が記述すること

は極めて困難です。機械学習は、このような複雑で、人間が明確なルールとして定義しにくい問題に対して、データから直接的に解決策(モデル)を導き出すことを可能にします。これが、画像認識³⁵や自然言語処理²⁷、音声認識²⁷といった分野でAIが目覚ましい進歩を遂げている大きな理由の一つです。

教師あり学習: 正解ラベルがお手本

機械学習にはいくつかの学習方法がありますが、画像分類で最も一般的に用いられるのが「教師あり学習(Supervised Learning)」と呼ばれる手法です¹⁵。

教師あり学習は、コンピュータに「問題(入力データ)」と、それに対応する「正解(期待される出力、ラベル)」のペアを大量に与えて学習させる方法です¹⁵。画像分類の場合、「問題」は画像データ、「正解」はその画像がどのカテゴリーに属するかを示すラベル(例:「犬」「猫」「車」など)になります。正解がまるで先生のように与えられることから、「教師あり」学習と呼ばれます²⁸。

コンピュータ(学習アルゴリズム)は、これらの「問題と正解」のペアを繰り返し学習する中で、入力された画像データの特徴(色、形、テクスチャなど)と、それに対応する正解ラベルとの間の関連性やパターンを統計的に見つけ出そうとします⁸。学習が進むにつれて、モデルは入力データから正解ラベルを予測するための内部的なルールを構築していきます。最終的には、学習データに含まれていなかった未知の画像が入力された際にも、学習によって獲得した知識(モデル)を用いて、それがどのカテゴリーに属する可能性が高いかを高い精度で予測できるようになることを目指します²³。

このプロセスは、人間が新しい概念を学ぶ過程に似ています。例えば、子供に様々な種類の犬の写真を見せながら「これは犬だよ」と繰り返し教えることで、子供は犬に共通する特徴(耳の形、鼻の形、毛並みなど)を無意識のうちに学習し、初めて見る犬に対しても「これは犬だ」と認識できるようになります⁸。教師あり学習も、これと同様に、大量の正解付き事例からパターンを一般化する能力をコンピュータに与える試みと言えます。

教師あり学習は、主に「分類(Classification)」と「回帰(Regression)」という2種類のタスクに適用されます²⁶。分類は、データをあらかじめ定義されたカテゴリーのいずれかに割り当てるタスクです(例: 画像が犬か猫かを判断する²³、メールがスパムか否かを判定する²⁴)。回帰は、連続的な数値を予測するタスクです(例: 過去のデータから明日の気温や株価を予測する²³)。画像分類は、このうち「分類」タスクの代表的な例です²³。

4. 画像分類はどうやって進めるの？ ステップ解説

機械学習を用いた画像分類のプロジェクトは、一般的に以下のステップで進められます。

ステップ1: 学習データの準備(収集とラベル付け)

画像分類モデルを開発する上で、最初にして最も重要なステップが、学習に使用するデータを準備

することです。モデルの性能は、学習データの質と量に大きく依存するため、このステップには十分な時間と注意を払う必要があります⁴。

- **データ収集:** まず、分類したい対象の画像をできるだけ多く集めます⁴。例えば、「犬」「猫」「鳥」の3種類に分類するモデルを作るなら、それぞれの動物の画像を多数収集します。
- **品質と多様性の確保:** 集める画像は、できるだけ高画質で、対象がはっきりと写っているものが望ましいです⁴。また、モデルが様々な状況に対応できるように、多様な条件下で撮影された画像を含めることが重要です。具体的には、異なる角度、明るさ、背景、大きさ、種類(犬なら犬種など)の画像をバランス良く集めることを目指します⁴。不鮮明な画像や、分類対象と関係のないものが大きく写り込んでいる画像は、学習の妨げになる可能性があるため、事前に除去するか、後述する前処理で改善します⁴。
- **ラベル付け(アノテーション):** 収集した画像データだけでは、コンピュータは何を学習すれば良いのか分かりません。そこで、教師あり学習では、各画像に対して「これが何であるか」を示す正解ラベルを付ける作業が必要になります⁴。この作業は「アノテーション」や「ラベリング」と呼ばれます⁴。例えば、犬の画像には「犬」、猫の画像には「猫」というラベルを付けます。このラベル付けの正確さが、最終的なモデルの精度に直接影響を与えるため、非常に慎重に行う必要があります⁴。アノテーション作業には、専用のツールが使われることもあります⁶。
- **データ量のバランス:** 各カテゴリー(クラス)の画像枚数に大きな偏りがあると、モデルが多数派のクラスばかりを予測するようになってしまう可能性があります⁴。そのため、できるだけ各クラスのデータ数を均等に近づけることが望ましいです。データが少ないクラスについては、画像を回転させたり、明るさを変えたりして擬似的にデータを増やす「データ拡張(Data Augmentation)」というテクニックが用いられることもあります⁹。
- **データ分割:** 準備したデータセット全体を、通常は3つのグループに分割します⁹。
 - **学習用データ(Training Data):** モデルのパラメータを学習・調整するために使用します。最も多くのデータが割り当てられます(例: 全体の70-80%)。
 - **検証用データ(Validation Data):** 学習の途中でモデルの性能を評価し、学習の進め方(ハイパーパラメータ)を調整したり、過学習(後述)が起きていないかを確認したりするために使用します(例: 全体の10-15%)。
 - **評価用データ(Test Data):** 学習と検証が完了した後、最終的に完成したモデルが未知のデータに対してどれくらいの性能を発揮するかを公平に評価するために使用します(例: 全体の10-15%)。このデータは、モデルの学習や調整には一切使用しません。

データ準備の工程は、AI開発プロジェクト全体の中でも特に時間と労力、そしてコストがかかる部分です⁴⁸。高品質なデータを大量に集め、正確にラベル付けを行うことは、時に非常に困難な作業となります(例えば、めったに発生しない製品不良の画像を集めるのは難しい⁵¹)。しかし、この工程がモデル性能の土台を築くため、その重要性は計り知れません。「Garbage In, Garbage Out(ゴミを入れればゴミが出る)」という言葉があるように、不適切なデータからは良いモデルは生まれません⁴⁹。

ステップ2: コンピュータモデルの訓練(学習)

学習データの準備ができたなら、次はそのデータを使ってコンピュータモデル(AI)を訓練(学習)させるステップです⁴。

- 特徴量の学習: モデルは、学習用データ(画像のピクセル情報とその正解ラベル)を入力として受け取ります。そして、画像の中から、特定のクラス(例:「犬」)を他のクラス(例:「猫」)と区別するのに役立つ「特徴量」を自動的に見つけ出す方法を学習します⁴。特徴量とは、画像の色、形、テクスチャ、エッジ(輪郭)など、画像の内容を表す数値的な情報のことです。
- 予測と誤差の計算: 学習中、モデルは入力された学習用画像に対して、それがどのクラスに属するかを予測します²⁵。そして、その予測結果と、あらかじめ与えられている正解ラベルを比較し、どれだけ予測が間違っていたか(誤差、または損失 Loss と呼ばれます)を計算します⁵³。
- パラメータの調整: モデルの内部には、予測の仕方を決定する多数の調整可能なパラメータ(重み Weight やバイアス Bias と呼ばれる数値)が存在します。学習アルゴリズム(例: 勾配降下法²⁵)は、計算された誤差をできるだけ小さくするように、これらのパラメータの値を少しずつ更新・調整していきます⁵³。
- 反復学習: この「予測→誤差計算→パラメータ調整」というプロセスを、学習用データセット全体を使って何度も何度も繰り返します²⁴。この繰り返し(エポック Epoch と呼ばれます)を経ることで、モデルは徐々に画像の特徴とラベルの関係性を正確に捉えるようになり、予測精度を高めていきます。

この学習プロセスは、本質的には「最適化問題」を解くことに相当します。つまり、モデルの予測と正解との間の「誤差(損失関数で定義される)」を最小にするようなパラメータの組み合わせを見つけ出すことが目標となります。この視点は、学習の進行具合を調整する「学習率(Learning Rate)」⁵³ や、誤差をどのように計算しパラメータを更新するかを決める「最適化アルゴリズム(Optimizer)」⁵³ の選択がなぜ重要なかを理解する上で役立ちます。

モデルの訓練には、特に大量のデータや複雑なモデル(後述するCNNなど)を用いる場合、膨大な計算が必要です。そのため、計算を高速化するために、画像処理に特化した高性能なプロセッサであるGPU(Graphics Processing Unit)がしばしば利用されます⁷¹。

ステップ3: モデルの性能評価(精度はどれくらい?)

モデルの訓練(学習)が完了したら、そのモデルが実際にどれだけうまく画像を分類できるのか、その性能を客観的に評価する必要があります⁴。

- 評価用データ(テストデータ)の使用: 性能評価には、モデルの学習や調整には一切使用していない「評価用データ(テストデータ)」を用います⁹。これにより、モデルが学習データだけを記憶してしまった(過学習)のではなく、未知の新しいデータに対しても正しく分類できる能力(これを「汎化性能」と呼びます²³)を持っているかを測ることができます。
- 評価指標: モデルの性能を数値で表すために、いくつかの評価指標が用いられます。どの指標を重視するかは、解決したい課題の性質によって異なります。
 - 混同行列 (Confusion Matrix): 評価の基本となるのが混同行列です。これは、モデルの予測結果と実際の正解クラスを比較し、どのクラスがどのクラスとして分類されたか

をまとめた表です⁴。以下の4つの要素から構成されます。

- 真陽性 (True Positive, TP): 正解が「陽性」であり、予測も「陽性」だった数⁶²。
- 真陰性 (True Negative, TN): 正解が「陰性」であり、予測も「陰性」だった数⁶²。
- 偽陽性 (False Positive, FP): 正解は「陰性」なのに、予測が「陽性」だった数(第一種過誤)⁶²。
- 偽陰性 (False Negative, FN): 正解は「陽性」なのに、予測が「陰性」だった数(第二種過誤)⁶²。

- 主な評価指標: 混同行列の値を元に、以下の指標が計算されます。

| 指標名 | 意味 | 計算式 (例: 2クラス分類) | 重視する場面例 |
|------------------|---|---|--|
| 正解率 (Accuracy) | 全データのうち、正しく分類できた割合 | $TP+TN+FP+FN$ | データクラスのバランスが良い場合、全体的な性能を見たい時 ⁴ |
| 適合率 (Precision) | モデルが「陽性」と予測した中で、実際に陽性だった割合 | $TP+FP$ | 陽性と予測した結果の信頼性が重要な場合 (例: 迷惑メール判定、コストのかかる実験の候補選定) ⁴ |
| 再現率 (Recall) | 実際に陽性だったデータの中で、モデルが正しく陽性と予測できた割合 | $TP+FN$ | 陽性のデータを見逃したくない場合 (例: がん検診、不良品の検出) ⁴ |
| F1スコア (F1-Score) | 適合率と再現率のバランス (調和平均) | $2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$ | 適合率と再現率の両方をバランス良く評価したい場合 ⁴ |
| AUC | ROC曲線の下での面積。モデルの総合的な識別能力 (0.5~1、1に近いほど良い) | - | 閾値に依存しないモデル全体の性能を比較したい場合 ⁴ |

- 評価の重要性: モデルの評価は、単に一つの数値 (例えば正解率) を見るだけでは不十分です。特に、クラスごとのデータ数に偏りがある場合 (例えば、正常品画像が99枚、不良品画像が1枚)、すべての画像を「正常品」と予測するモデルでも正解率は99%になりますが、これでは不良品を見つけるという目的は達成できません⁷⁰。したがって、タスクの目的 (例えば、不良品の見逃し (FN) を防ぐことが重要か、正常品を誤って不良品と判定する (FP) のを防ぐことが重要か) に応じて、適合率や再現率といった複数の指標を考慮し、混同行列で詳細なエラーの傾向を分析することが不可欠です⁷⁰。
- チューニング: 評価の結果、モデルの性能が目標に達していない場合は、ステップ1 (データの見直し、追加、品質向上) やステップ2 (学習方法の調整、モデル構造の変更) に戻り、改善を図ります⁴。この試行錯誤のプロセスを「チューニング」と呼びます。

ステップ4: 新しい画像の分類(予測)

モデルの訓練と評価を経て、実用に足ると判断された学習済みモデルは、いよいよ未知の新しい画像を分類するために使われます⁴。このプロセスは「予測(Prediction)」や「推論(Inference)」と呼ばれます²³。

- 予測の実行: 新しい画像データを学習済みモデルに入力します。モデルは、内部に保持している学習済みのパラメータ(ルールやパターン)に基づいて、入力された画像の特徴を分析します²。
- 結果の出力: 分析結果に基づいて、モデルはその画像が事前に定義された各カテゴリーに属する確率を計算し、最も確率が高いカテゴリーを予測結果として出力します²。例えば、「この画像は95%の確率で犬、3%の確率で猫、2%の確率でその他」といった形式で出力されることがあります。
- 応用: この予測結果は、様々な目的に利用されます。例えば、スマートフォンの写真を人物や場所ごとに自動でフォルダ分けしたり⁷⁷、工場のラインで流れてくる製品が良品か不良品かを瞬時に判定したり¹¹、医療画像から異常の可能性を医師に提示したり²することができます。

ここで重要なのは、「学習(Training)」と「予測(Prediction/Inference)」は明確に区別されるべきフェーズであるという点です³⁹。学習は、時間と計算資源をかけてモデルを構築・最適化するプロセスです¹⁵。一方、予測は、その完成した学習済みモデルを使って、新しいデータに対して迅速に結果を得るプロセスです⁷。通常、AIシステムは、まず学習フェーズでモデルを作り上げ、その後、そのモデルを実際の運用(予測フェーズ)に投入するという流れになります。

5. 押さえておきたいキーワード

画像分類の仕組みを理解する上で、いくつか重要なキーワードがあります。これらの言葉の意味を知っておくと、より深く学習を進める助けになります。

- 特徴量 (Features / 特徴抽出 Feature Extraction)
 - 意味: 画像の中から、コンピュータが分類を行うための手がかりとなる情報(例えば、色、形、模様、線の向き、角など)を抽出し、数値データとして表現したものです⁴。コンピュータが画像を「理解」するための構成要素と言えます。
 - 抽出方法: 以前は、人間がどのような特徴量が有効かを考え、それを抽出するアルゴリズムを設計していました(これを「手動特徴量」や「人為的特徴量」と呼びます⁷)。しかし、近年の深層学習、特に後述するCNNのような技術では、コンピュータ自身がデータから自動的に有効な特徴量を発見し、抽出する方法を学習します(これを「自動特徴量」や「機械的手法」と呼びます¹¹)。
- ラベル (Label / アノテーション Annotation)
 - 意味: 教師あり学習において、学習データ(画像など)に対して付けられる「正解」の情報

報です⁴。画像分類では、その画像が属するカテゴリー名(例:「犬」「猫」)がラベルとなります。この正解ラベルがあることで、コンピュータは何を学習すべきかを知ることができます。「タグ」や「注釈」と呼ばれることもあります⁵。

- 関連作業: データにラベルを付ける作業そのものを「ラベリング」や「アノテーション」と呼びます⁴。

- **モデル (Model)**

- 意味: 機械学習によってデータから学習されたパターンやルールを内包した、予測や判断を行うための数学的な仕組みやプログラムのことです⁴。入力データを受け取り、学習した知識に基づいて、何らかの出力(画像分類の場合はカテゴリーの予測)を返します³¹。
- 構造: 画像分類では、後述するCNN(畳み込みニューラルネットワーク)のような特定の構造(アーキテクチャ)を持つモデルがよく用いられます⁴。

- **学習 (Learning / Training)**

- 意味: データ(教師あり学習の場合は入力データと正解ラベルのペア)を用いて、モデルがより正確な予測を行えるように、内部のパラメータを自動的に調整していくプロセスのことです⁴。モデルがデータから「経験」を積む過程と考えることができます。

- **予測 (Prediction / Inference)**

- 意味: 学習によって完成したモデルを使用して、未知の新しいデータ(例: 見たことのない画像)に対して、そのデータがどのカテゴリーに属するかなどを推測(判断)することです²。学習フェーズとは区別されます。

これらのキーワードは、それぞれ独立しているのではなく、密接に関連し合っています。画像分類のプロセス全体は、**「ラベル」付きの「データ」を準備し、そこから「特徴量」を抽出する方法を「モデル」が「学習」し、その学習済みモデルを使って未知のデータに対して「予測」**を行う、という一連の流れとして理解することができます。この流れの中で各キーワードがどのような役割を果たしているかを把握することが、画像分類の全体像を掴む鍵となります。

6. 画像認識のスター選手: CNN入門

画像分類、特に高精度なものが求められる場面で、現在最も広く使われ、大きな成功を収めている技術が「CNN(シーエヌエヌ)」、すなわち「畳み込みニューラルネットワーク(Convolutional Neural Network)」です²。

CNN(畳み込みニューラルネットワーク)とは？

CNNは、人間の脳の神経回路網(ニューラルネットワーク)の考え方をベースにした「深層学習(ディープラーニング)」と呼ばれる機械学習手法の一種です⁴⁶。特に、人間の視覚野(目で見た情報を処理する脳の領域)が、視野の中の小さな範囲(局所受容野)からエッジや線といった単純な特徴を検出し、それらを組み合わせでより複雑な形や物体を認識していく仕組みにヒントを得て設計され

ています⁴⁶。

CNNの基本的な構造は、主に以下の3種類の層(レイヤー)を組み合わせで構成されます²。

1. 畳み込み層 (Convolutional Layer): 画像から特徴を抽出する役割を担います。
2. プーリング層 (Pooling Layer): 抽出された特徴を圧縮し、位置のずれに対する耐性を持たせる役割を担います。
3. 全結合層 (Fully Connected Layer): 最終的に抽出・圧縮された特徴を統合し、分類結果を出力します。

通常、畳み込み層とプーリング層がペアになって複数回繰り返され、ネットワークの深い層でより複雑で抽象的な特徴を捉えられるように設計されています。

なぜ画像が得意？CNNの仕組み(畳み込み・プーリング)

CNNが画像認識タスクでこれほど高い性能を発揮する理由は、その独特の構造が画像データの持つ特性をうまく捉えるように設計されているからです。

- 畳み込み層 (Convolutional Layer):
 - この層では、「フィルター」(または「カーネル」)と呼ばれる小さな正方行列(例えば3x3ピクセルなど)が用意されます。このフィルターは、特定の特徴(例えば、縦線、横線、斜め線、特定の色や模様など)を検出するように設計されています。
 - フィルターが入力画像の上を少しずつスライドしながら移動し、各位置でフィルターとその下の画像領域との間で計算(畳み込み演算)を行います²。この計算結果が大きいほど、その位置にフィルターが探している特徴が存在することを示します。
 - この操作を画像全体に適用することで、入力画像内のどこにどのような局所的な特徴が存在するかを示す「特徴マップ (Feature Map)」が生成されます²²。
 - 一つの畳み込み層で複数の異なるフィルターを使用することで、エッジ、コーナー、テクスチャなど、様々な種類の特徴を同時に抽出できます²。
 - さらに、畳み込み層を深く重ねていくことで、最初の層では線やエッジのような単純な特徴を、後の層ではそれらを組み合わせた目や鼻のような部品、さらには物体全体の形状といった、より複雑で高次元特徴を段階的に学習していくことができます²²。これは、画像が持つ「階層的な構造」を捉えるのに適しています。
- プーリング層 (Pooling Layer):
 - 畳み込み層で抽出された特徴マップは、依然として多くの情報を含んでいます。プーリング層の目的は、この特徴マップの情報を圧縮し、より扱いやすくすることです²。
 - 一般的な方法として「最大プーリング (Max Pooling)」があります。これは、特徴マップを小さな領域(例えば2x2ピクセル)に分割し、各領域内の最大値だけを取り出して新しい、より小さな特徴マップを作成する処理です²。
 - この処理により、計算に必要なデータ量が削減されるだけでなく、重要な特徴を保持しつつ、物体の位置が画像内で多少ずれたり、わずかに変形したりしても、同じ特徴として認識されやすくなるという効果があります²。これは、画像認識における「位置不変性

(Translation Invariance)」と呼ばれる性質に対応するものです。

- **全結合層 (Fully Connected Layer):**
 - 畳み込み層とプーリング層を何度か繰り返した後、最終的に得られた特徴量をすべて受け取り、それらを統合して、元の画像がどのクラスに属するかの最終的な確率を計算します²。ここで計算された確率に基づいて、最も可能性の高いクラスが予測結果として出力されます。

CNNの成功の核心は、画像データが持つ固有の性質、すなわち「空間的な局所性(近くのピクセルは関連性が高い)」「階層性(単純な特徴が組み合わさって複雑な特徴になる)」「並進不変性(物体は画像のどこにあっても同じ物体)」を、ネットワークの構造自体に組み込んでいる点にあります。畳み込み層は局所性と階層性を捉え、プーリング層は並進不変性を強化します。また、「重み共有 (Weight Sharing)」という仕組み(同じフィルターを画像全体で使い回す)により、学習すべきパラメータ数を大幅に削減し、効率的な学習を可能にしています⁸⁴。これらの「構造的な工夫(バイアス)」が、CNNを画像認識のための強力なツールたらしめているのです。

7. 私たちの周りの画像分類: 活用事例集

機械学習による画像分類技術は、すでに実験室の中だけのものではなく、私たちの日常生活や様々な産業分野で広く活用され、効率化、安全性向上、新しいサービスの創出に貢献しています。

写真の整理から自動運転まで

- **写真・動画の整理と検索:** スマートフォンやクラウドストレージの写真アプリでは、写っている人物の顔、場所、イベントの種類などを画像分類技術で認識し、自動的にアルバムを作成したり、タグ付けしたりする機能が一般的になっています⁷⁷。これにより、膨大な写真の中から目的のものを簡単に見つけ出すことができます。同様に、ソーシャルメディア(SNS)では、アップロードされた写真の内容を解析し、関連性の高いタグを自動で付与したり、不適切なコンテンツをフィルタリングしたりするのに役立っています²。
- **自動運転支援:** 完全な自動運転システムの実現には、画像分類だけでなく、物体の位置を特定する物体検出やセンサー情報など、様々な技術の統合が必要ですが、画像分類も重要な役割を担っています。例えば、道路標識(速度制限、一時停止など)や信号機の色を認識し、車両の制御に反映させるために利用されています²。路面状態(乾燥、湿潤、凍結、積雪)の自動判定にも応用され、安全運転支援や防災への活用が期待されています¹⁵。

医療、製品検査、顔認証など

画像分類技術の応用範囲は非常に広く、以下のような多様な分野でその価値を発揮しています。

- **医療分野:** MRI、CT、X線、内視鏡などの医療画像を解析し、がん細胞やその他の病変、異常

箇所を検出することで、医師の診断を支援するシステムが開発・導入されています²。これにより、病気の早期発見や診断精度の向上が期待されます。例えば、国立がん研究センターでは、AIによる内視鏡画像解析で高い病変発見率を達成したと報告されています³。

- 製造業(製品検査・品質管理): 工場の生産ラインにおいて、カメラで撮影した製品画像をAIが分析し、傷、汚れ、欠け、異物混入などの不良品を自動的に検出・選別するシステムが導入されています²。これにより、検査工程の効率化、人件費削減、品質の安定化が実現します。食品(マグロの品質判定¹⁴、カット野菜の検査³)、飲料(ワインの異物検査¹⁴)、電子部品、自動車部品など、幅広い製品が対象となっています。
- セキュリティ・認証: 顔認証技術は画像分類の代表的な応用例です。空港の出入国審査ゲート¹⁰、オフィスビルや施設の入退室管理²、スマートフォンのロック解除²など、個人の識別と認証が必要な場面で広く利用されています。マスク着用時でも認識可能なシステム¹⁹や、顔認証による決済システム⁹⁰も登場しています。また、防犯カメラ映像を解析し、不審な行動を検知して警告を発するシステム²や、万引き防止⁹¹にも活用されています。
- 小売・流通:
 - 在庫管理・棚卸し: 倉庫や店舗の商品棚をカメラで撮影し、画像分類によって商品の種類と数量を自動的に認識・カウントすることで、在庫管理や棚卸し作業を効率化します³。欠品を自動で検知し、発注を促すシステムもあります⁵。
 - 無人店舗・レジ自動化: Amazon Go⁴⁶のような無人店舗では、顧客が手に取った商品をカメラとAIが認識し、自動で決済が行われます。また、パン屋¹²やスーパーマーケット³では、レジに置かれた商品をカメラが自動で識別し、価格を計算するシステムが導入され、レジ業務の高速化と省人化に貢献しています。
 - ECサイト: ユーザーがスマートフォンのカメラで撮影した商品や、ウェブサイトで見つけた商品の画像をアップロードすると、AIが類似の商品をECサイト内から検索してくれる機能があります²。これにより、商品名が分からなくても直感的に欲しいものを見つけることができます。
- 農業・漁業: 農作物の品質選別(例: ワイン用ブドウ¹⁰)や、ドローンで撮影した圃場の画像から作物の生育状況を把握したり、病害虫の発生を早期に発見したりするのに利用されています²。漁業では、マグロの尾の断面画像から品質を判定する技術¹⁴などに応用されています。また、海氷の分布状況を衛星画像から把握し、船舶の安全航行に役立てる研究も進んでいます⁹¹。
- その他: 上記以外にも、建設現場での安全確保(危険エリアへの侵入検知³)、インフラ点検(コンクリート構造物のひび割れ検出⁹¹)、スポーツ中継でのハイライトシーン自動抽出⁹⁰、SNS投稿写真の分析によるトレンド予測や顧客ニーズ把握⁸⁸など、画像分類技術の応用範囲は日々拡大しています。

これらの事例を見てわかるように、画像分類技術は単独で機能するだけでなく、物体検出、センサー技術、ロボティクス、自然言語処理といった他の技術と連携することで、より高度で複雑なシステムやソリューション(例えば、自動運転、スマートファクトリー、無人店舗、AI診断支援など)を実現するための重要な基盤技術として機能しています。この「組み合わせ」によって、画像分類の可能性はさらに広がっていくと考えられます。

8. 画像分類の難しさと注意点

画像分類技術は非常に強力で、多くの分野で活用されていますが、万能ではありません。実際にモデルを開発し、運用する際には、いくつかの難しさや注意すべき点が存在します。

データに関する課題

機械学習モデル、特に画像分類モデルの性能は、学習データの質と量に大きく依存するため、データに起因する課題が多く存在します。

- 大量の高品質な学習データが必要: 高い精度と汎化性能を持つモデルを構築するには、通常、非常に大量の画像データが必要です⁴。さらに、これらのデータはノイズが少なく、対象が明確に写っており、かつ正確なラベルが付与されている「高品質」なものである必要があります。このようなデータを大量に収集し、整備（アノテーションを含む）するには、多大な時間、労力、そしてコストがかかることが、プロジェクト推進上の大きな障壁となる場合があります⁴⁸。
- データの偏り（不均衡）: 学習データセット内のクラスごとのデータ数に大きな偏りがあると、モデルはデータ数の多いクラスを優先的に学習してしまい、データ数の少ないクラスに対する分類精度が低下する傾向があります⁴。例えば、製品の異常検知タスクでは、正常品のデータは大量に入手できても、異常品のデータは発生頻度が低いために少量しか得られない、という状況がしばしば発生します⁵¹。このようなデータ不均衡の問題に対処するには、データ拡張技術を用いたり、学習アルゴリズム側で工夫したりする必要があります。
- データの品質とノイズ: 学習データに含まれる画像の品質が低い場合（例：ピンボケ、露出不足・過多、ノイズが多い、対象が隠れている⁴）や、ラベル付けに誤りがある場合⁶、モデルは正しいパターンを学習できず、性能が著しく低下します⁴⁹。単純にデータの量だけを増やしても、その質が悪ければ、かえって性能が悪化することさえあります⁴⁹。
- 撮影環境の変動: 学習時に使用した画像の撮影環境（照明条件、カメラの種類・設定、撮影角度、背景など）と、実際にモデルを運用する際の環境が大きく異なると、モデルの性能が大幅に低下することがあります⁹。安定した性能を得るためには、できるだけ運用環境に近い条件で学習データを収集するか、様々な環境下で撮影された多様なデータを用いて、環境変動に頑健（ロバスト）なモデルを学習させる必要があります。

その他の考慮事項

データ以外にも、以下のような点を考慮する必要があります。

- 類似画像の識別限界: 人間の目でも区別が難しいような、非常によく似た画像をコンピュータが高精度で分類することは、依然として困難な場合があります⁸。例えば、微妙な違いしかない製品の不良品判定や、酷似したブランドロゴの識別などが挙げられます。
- モデルの複雑さと計算コスト: 高い精度を達成するモデル、特にCNNのような深層学習モデルは、内部構造が非常に複雑で、多数のパラメータを持っています¹⁷。そのため、モデルの学習には高性能なコンピュータ（特にGPU）と長い時間が必要になることがあります⁷¹。また、学習

済みのモデルを実際のデバイス(スマートフォンや組み込みシステムなど)で動かす際にも、計算能力やメモリ容量の制約から、そのままでは利用できない場合があります。このような場合には、モデルの精度を維持しつつサイズを小さくする「モデル圧縮」や「蒸留」といった技術が必要になることがあります⁴。

- **過学習 (Overfitting):** モデルが学習データを「暗記」しすぎてしまい、学習データに対しては非常に高い精度を示すものの、未知の新しいデータに対してはうまく対応できなくなる現象です⁴³。汎化性能が低い状態であり、実用上問題となります。過学習を防ぐためには、学習データの量を増やす、データ拡張を行う⁴³、モデルの複雑さを抑制する(正則化⁵²)、学習を適切なタイミングで打ち切る(早期終了⁴⁷)などの対策が取られます。
- **説明可能性(ブラックボックス問題):** 深層学習モデル、特にCNNは、なぜそのような予測結果に至ったのか、その判断根拠を人間が理解することが難しい場合があります⁵¹。モデルの内部動作が複雑で不透明であるため、「ブラックボックス」と喩えられます。医療診断支援や自動運転など、誤った判断が重大な結果を招く可能性がある分野では、この説明可能性の欠如が大きな課題となります。近年、モデルの判断根拠を可視化する技術(例:ヒートマップ⁵¹)の研究も進んでいます。
- **精度と速度のトレードオフ:** 一般的に、モデルの精度を高めようとすると、モデル構造が複雑になったり、計算量が増えたりして、予測にかかる時間(処理速度)が遅くなる傾向があります⁴。リアルタイムでの処理が求められる応用(例:自動運転、製造ラインでの高速検査)では、許容される処理時間内に予測を完了させる必要があります。そのため、要求される精度と速度のバランスを考慮し、最適なモデルを選択・設計することが重要になります⁴。

これらの課題や考慮事項を踏まえると、画像分類モデルを実世界で成功裏に導入・運用するためには、単に技術的な精度(Accuracyなどの指標)を追求するだけでは不十分であることがわかります。データの準備・管理にかかるコスト、必要な計算資源、運用環境の制約、モデルの判断に対する説明責任、そして最終的にその技術導入によって得られるビジネス上の価値(投資対効果、ROI)といった、多岐にわたる現実的な要因を総合的に評価し、バランスの取れた意思決定を行うことが不可欠です¹⁰。

9. まとめ: 画像分類の世界への第一歩

このガイドでは、機械学習を用いた画像分類の基本的な概念から、その仕組み、具体的な手順、応用例、そして開発・運用における課題に至るまで、初心者の方にも理解しやすいように解説してきました。

基本の振り返り:

- 画像分類とは、画像全体が何を表しているかをコンピュータが自動で判断する技術です。
- 機械学習、特に教師あり学習を用いることで、コンピュータは大量の正解付きデータから画像の特徴とカテゴリーの関係を学習します。
- 画像分類のプロセスは、①データ準備(収集・ラベル付け)、②モデル訓練(学習)、③性能評価、**④予測(推論)**というステップで進められます。
- 特徴量、ラベル、モデル、学習、予測といったキーワードが、このプロセスを理解する上で重要

です。

- **CNN(畳み込みニューラルネットワーク)**は、画像の特性を捉えるのに適した構造を持ち、画像認識分野で広く使われる強力なモデルです。
- 画像分類技術は、写真整理、医療診断支援、製品検査、顔認証、自動運転支援、小売など、私たちの身の回りの非常に多くの場面で活用されています²。
- 一方で、高品質なデータの確保、モデルの複雑さ、過学習、説明可能性など、克服すべき課題も存在します。

次のステップへ：

画像分類は、コンピュータが視覚情報、つまり画像を「理解」するための入り口となる技術です。このガイドを通じて、その基本的な考え方や可能性を感じていただけたなら幸いです。

もし、さらに深く学んでみたい、あるいは実際に試してみたいと思われた方は、次のようなステップに進むことができます。

- 簡単なツールを試す: MicrosoftのCustom Vision⁹⁴ やGoogle Cloud AutoML Visionなどのサービスを使えば、プログラミングなしで独自の画像分類モデルを作成・試用することができます。
- プログラミングに挑戦する: Python言語と、TensorFlow⁷¹ やPyTorch⁵³ といった機械学習ライブラリを使えば、より自由にモデルを構築し、学習プロセスを制御することができます。オンラインには多くのチュートリアルや学習教材があります⁷¹。
- より高度な技術を学ぶ: CNNIには様々な発展形(AlexNet, VGG, GoogLeNet, ResNet, DenseNetなど⁴)があり、それぞれ特徴が異なります。また、物体検出やセグメンテーション¹⁷ など、画像認識にはさらに高度なタスクも存在します。

AIと機械学習、特に画像認識の分野は日進月歩で進化を続けています²。このガイドが、皆さんがこのエキサイティングな技術分野への興味を深め、学びを進めるための一助となれば嬉しく思います。

引用文献

1. note.com, 4月 24, 2025にアクセス、
<https://note.com/humanome/n/n2d61f5c8e56e#:~:text=%E7%94%BB%E5%83%8F%E5%88%86%E9%A1%9E%E3%81%AF%E3%80%81%E7%94%BB%E5%83%8F%E5%85%A8%E4%BD%93,%E3%81%AE%E3%82%88%E3%81%86%E3%81%AA%E6%99%82%E3%81%A7%E3%81%99%E3%80%82&text=%E5%86%99%E7%9C%9F%E5%85%A8%E4%BD%93%E3%81%AB%E5%A4%A7%E3%81%8D%E3%81%8F1.%E9%81%B8%E3%81%B6%E3%81%AE%E3%81%8C%E9%81%A9%E5%88%87%E3%81%A7%E3%81%99%E3%80%82>
2. 画像分類とは？ - CNNモデルを用いた画像の識別と応用 | だいしょう, 4月 24, 2025にアクセス、https://note.com/mindful_otaku/n/n097976434ac3
3. AI/機械学習による画像分類とは？ 導入方法や活用事例8選も紹介 - AI総研, 4月 24, 2025にアクセス、<https://metaversesouken.com/ai/ai/image-classification/>
4. 画像分類とは？ AIモデルや作成フロー、活用例、注意点を徹底解説！, 4月 24, 2025にアクセス、<https://www.nextremer.com/data-annotation/blog/image-classification>
5. 画像アノテーションとは？事例と作業効率化のためのヒント | Appen, 4月 24, 2025にアクセス、<https://appen.co.jp/blogs/what-is-image-annotation>

6. 画像アノテーションのやり方は？手法や手順・注意点・外注か内製かについて徹底解説！, 4月 24, 2025にアクセス、
<https://www.nextremer.com/data-annotation/blog/image-annotation-process>
7. 初心者でもわかる！画像解析の基本的なやり方と注意点, 4月 24, 2025にアクセス、
<https://www.silk.co.jp/column/image-analysis-2/>
8. 画像分類と物体検知は何が違うの？ | 株式会社ヒューマノーム研究 ..., 4月 24, 2025にアクセス、
<https://note.com/humanome/n/n2d61f5c8e56e>
9. AI・機械学習による画像分類とその活用法とは？, 4月 24, 2025にアクセス、
<https://products.sint.co.jp/aisia-ad/blog/image-recognition-ai2>
10. AIによる画像分類とは？画像全体を理解する画像認識の特徴・活用 ..., 4月 24, 2025にアクセス、
<https://ai-market.jp/purpose/image-recognition-classification/>
11. AI・機械学習による画像分類とは？学習モデルや活用例・精度向上の ..., 4月 24, 2025にアクセス、
https://aismiley.co.jp/ai_news/ai-machine-learning-image-classification/
12. 機械学習における画像分類とは？導入された事例と学習方法も解説 - Tech Teacher, 4月 24, 2025にアクセス、
<https://www.tech-teacher.jp/blog/machine-learning-image-classification/>
13. 画像分類とはどんな技術？仕組みやAI活用時の注意点を解説, 4月 24, 2025にアクセス、
<https://www.hitachi-systems-es.co.jp/service/column/ai/article06.html>
14. AIによる画像分類とは | 概要や事例を紹介 - CMC Japan, 4月 24, 2025にアクセス、
<https://cmc-japan.co.jp/blog/ai-image-classification/>
15. AI・機械学習を用いた画像分類とは？その方法、実活用例を徹底解説 ..., 4月 24, 2025にアクセス、
<https://www.matrixflow.net/case-study/16/>
16. AI(ディープラーニング)による画像分類とその活用法【初級者向け】, 4月 24, 2025にアクセス、
<https://products.sint.co.jp/aisia-ad/blog/image-classification>
17. 【2025】画像認識AIとは？画像認識AIの仕組みとアーキテクチャを徹底解説 | AI研究所, 4月 24, 2025にアクセス、
<https://ai-kenkyujo.com/artificial-intelligence/algorithm/ai-image/>
18. 機械学習・深層学習による画像認識入門 #画像処理 - Qiita, 4月 24, 2025にアクセス、
https://qiita.com/iitachi_tdse/items/90435aef7c8d5ee1a78a
19. 画像認識とは？技術の種類や活用事例、今後の課題などをわかりやすく解説 - Japan IT Week, 4月 24, 2025にアクセス、
<https://www.japan-it.jp/hub/ja-jp/blog/article-37.html>
20. アノテーションとは？意味や必要性、AI機械学習に必要な作業を解説 - American Express, 4月 24, 2025にアクセス、
<https://www.americanexpress.com/ja-jp/business/trends-and-insights/articles/annotation/>
21. 【解説】アノテーションとは？意味や種類を解説！, 4月 24, 2025にアクセス、
<https://www.micro-wave.net/column/detail/annotation.html>
22. 畳み込みニューラルネットワーク(CNN)とは？画像認識に強い理由・活用事例・特徴・ディープラーニング他手法との関係を徹底解説！ - AI Market, 4月 24, 2025にアクセス、
<https://ai-market.jp/purpose/image-recognition-cnn/>
23. 機械学習とは？教師ありなし・強化学習などの種類も簡単にわかりやすく解説！, 4月 24, 2025にアクセス、
<https://www.agaroot.jp/datascience/column/machine-learning/>

24. 機械学習とは？機械学習の仕組みとディープラーニングとの違いを分かりやすく解説 | GSLコラム, 4月 24, 2025にアクセス、
<https://www.nttdata-gsl.co.jp/related/column/what-is-machine-learning.html>
25. 機械学習とは？種類や仕組み・活用例を簡単にわかりやすく解説 - さくマガ, 4月 24, 2025にアクセス、<https://sakumaga.sakura.ad.jp/entry/what-is-machine-learning/>
26. 機械学習とは - SAS, 4月 24, 2025にアクセス、
https://www.sas.com/ja_jp/insights/analytics/machine-learning.html
27. 機械学習とは？仕組み、手法、学び方から利用例まで - MATLAB & Simulink - MathWorks, 4月 24, 2025にアクセス、
<https://jp.mathworks.com/discovery/machine-learning.html>
28. 【初心者向け】機械学習とはデータのパターンやルールを見つける技術！種類や活用事例をわかりやすく解説 - 株式会社電算システム, 4月 24, 2025にアクセス、
<https://www.dsk-cloud.com/blog/machine-learning>
29. 機械学習の仕組みとは？学習方法や活用事例まで徹底解説！ - 株式会社G-gen (ジージェン), 4月 24, 2025にアクセス、
<https://g-gen.co.jp/useful/General-tech/13337/index.html>
30. 機械学習モデルとは？重要とされる理由や作成手順を紹介, 4月 24, 2025にアクセス、
<https://products.sint.co.jp/aisia-ad/blog/machine-learning-model>
31. 機械学習モデルとは？～主な種類と選ぶポイント - NTTデータ イントラマート, 4月 24, 2025にアクセス、<https://www.intra-mart.jp/im-press/useful/machine-learning>
32. 機械学習 | 用語解説 | 野村総合研究所(NRI), 4月 24, 2025にアクセス、
https://www.nri.com/jp/knowledge/glossary/machine_learning.html
33. 機械学習によるデータ分析とは？機械学習の種類・統計学との違い・手法や活用事例について詳しく解説！ - Yellowfin, 4月 24, 2025にアクセス、
<https://yellowfin.co.jp/blog/jpblog-data-analysis-using-machine-learning>
34. 機械学習モデルとは？種類や作り方から活用事例まで徹底解説！, 4月 24, 2025にアクセス、https://www.uis-inf.co.jp/dins/column/column_learning.html
35. 機械学習における学習データの重要性？作り方や種類を解説 - AIポータルメディア Alsmiley, 4月 24, 2025にアクセス、
https://aismiley.co.jp/ai_news/what-is-the-learning-data-that-is-essential-for-improving-ai-precision-accuracy/
36. www.uis-inf.co.jp, 4月 24, 2025にアクセス、
https://www.uis-inf.co.jp/dins/column/column_learning.html#:~:text=%E6%A9%9F%E6%A2%B0%E5%AD%A6%E7%BF%92%E3%83%A2%E3%83%87%E3%83%AB%E3%81%A8%E3%81%AF%E3%80%81%E5%A4%A7%E9%87%8F%E3%81%AE%E3%83%87%E3%83%BC%E3%82%BF%E3%81%8B%E3%82%89%E3%82%B3%E3%83%B3%E3%83%94%E3%83%A5%E3%83%BC%E3%82%BF%E3%83%BC.%E3%81%A7%E6%B4%BB%E7%94%A8%E3%81%95%E3%82%8C%E3%81%A6%E3%81%84%E3%81%BE%E3%81%99%E3%80%82
37. 機械学習モデルとは！？基礎知識・重要性を詳しく解説！ - 株式会社電算システム, 4月 24, 2025にアクセス、
<https://www.dsk-cloud.com/blog/what-is-machine-learning-model>
38. AIモデルとは？機械学習モデルの種類やアルゴリズムとの違いを解説 - Alsmiley, 4月 24, 2025にアクセス、https://aismiley.co.jp/ai_news/ai-models/
39. 【機械学習】推定・推論・予測 |  なんとか生きてる - note, 4月 24, 2025にアクセス、

- https://note.com/engineer_hino/n/nff7937d25875
40. 生成AIと予測AIの比較違いの理解 | SS&C Blue Prism, 4月 24, 2025にアクセス、
<https://www.blueprism.com/japan/resources/blog/generative-ai-vs-predictive-ai/>
 41. 機械学習の予測モデルとは？ 予測モデルの種類・作り方・事例紹介 | AI活用・AI導入事例の紹介, 4月 24, 2025にアクセス、<https://www.matrixflow.net/case-study/80/>
 42. AI 機械学習、ディープラーニング(深層学習)の違いとは？: データ活用のヒント(コラム) | NEC, 4月 24, 2025にアクセス、
<https://jpn.nec.com/solution/dotdata/tips/deep-learning/index.html>
 43. 10分で理解できるディープラーニングによる画像分類のポイント #機械学習 - Qiita, 4月 24, 2025にアクセス、https://qiita.com/kouta_hara/items/c196f138830d02355ce8
 44. 機械学習での画像分類・画像認識の流れとポイント | Koto Online, 4月 24, 2025にアクセス、<https://www.cct-inc.co.jp/koto-online/archives/247>
 45. 機械学習とは？ 学習の種類や予測プロセスの紹介, 4月 24, 2025にアクセス、
<https://www.acceluniverse.com/blog/developers/2019/11/post-24.html>
 46. 機械学習とCNNによる画像認証とは？ 画像認証の仕組みと活用事例を紹介 - Wakka Inc., 4月 24, 2025にアクセス、<https://wakka-inc.com/blog/20521/>
 47. PyTorchで画像分類モデルのトレーニングを行うまでの基本的な流れ - Qiita, 4月 24, 2025にアクセス、<https://qiita.com/ssc-nurabe/items/a3e5c9e5255f526a2977>
 48. AI画像技術とは？ 進化と未来の展望を分かりやすく解説します - Creative Drive, 4月 24, 2025にアクセス、<https://creative-drive.jp/column/510/>
 49. 画像の機械学習が劣化する理由 #DeepLearning - Qiita, 4月 24, 2025にアクセス、
<https://qiita.com/nonbiri15/items/2bd2320d8268321c331d>
 50. 機械学習でなんとかしようと安易に考えるな - Qiita, 4月 24, 2025にアクセス、
<https://qiita.com/nonbiri15/items/cfc6909ff71273b63f5e>
 51. 画像認識AIの精度を上げるテクニック【中級者向け】 - 株式会社システムインテグレータ, 4月 24, 2025にアクセス、
<https://products.sint.co.jp/aisia-ad/blog/image-recognition-ai-technique>
 52. 画像分類 | 過学習を防ぐ7つの対策と評価方法【事例あり】 - Hakky Handbook, 4月 24, 2025にアクセス、
<https://book.st-hakky.com/purpose/image-classification-overfitting-prevention/>
 53. 【超初心者向け】一行一行解説する画像分類CNNチュートリアル(演習Notebook付き) - Qiita, 4月 24, 2025にアクセス、
<https://qiita.com/GesonAnko/items/20fcffb4ff265d43a4dd>
 54. PyTorchとEfficientNetV2で作る画像分類モデル - Zenn, 4月 24, 2025にアクセス、
<https://zenn.dev/aidemy/articles/f851fb091dbb23>
 55. AIの精度を左右するデータラベリングとは？ 必要性や方法を解説 - Alsmiley, 4月 24, 2025にアクセス、
https://aismiley.co.jp/ai_news/what-is-annotation-in-ai-development/
 56. データのラベル付けとは - Google Cloud, 4月 24, 2025にアクセス、
<https://cloud.google.com/use-cases/data-labeling?hl=ja>
 57. 画像ラベル付けプロジェクトを設定する - Azure Machine Learning - Learn Microsoft, 4月 24, 2025にアクセス、
<https://learn.microsoft.com/ja-jp/azure/machine-learning/how-to-create-image-labeling-projects?view=azureml-api-2>
 58. 画像分類モデルの作成 - 日本語ドキュメント - Apple Developer, 4月 24, 2025にアクセス

- ス、
https://developer.apple.com/jp/documentation/createml/creating_an_image_classifier_model/
59. けしからん画像分類器を作ってみる (2) データ収集 その1 - Zenn, 4月 24, 2025にアクセス、<https://zenn.dev/kleample/articles/202102-pornography-classifier-2>
 60. www.nextremer.com, 4月 24, 2025にアクセス、
<https://www.nextremer.com/data-annotation/blog/image-annotation-process#:~:text=%E3%82%AD%E3%83%BC%E3%83%9D%E3%82%A4%E3%83%B3%E3%83%88%E3%82%A2%E3%83%8E%E3%83%86%E3%83%BC%E3%82%B7%E3%83%A7%E3%83%B3%E3%81%AF%E3%80%81%E7%94%BB%E5%83%8F,%E3%81%8C%E6%B4%BB%E7%94%A8%E3%81%95%E3%82%8C%E3%81%A6%E3%81%84%E3%81%BE%E3%81%99%E3%80%82>
 61. 【2025】アノテーションとは？7種類の分類とアノテーションのやり方を紹介 - AI研究所, 4月 24, 2025にアクセス、
<https://ai-kenkyujo.com/artificial-intelligence/annotation/toha-3/>
 62. 画像分類の精度向上法 | AI活用でビジネス成長を実現 | Hakky ..., 4月 24, 2025にアクセス、
<https://book.st-hakky.com/purpose/improving-image-classification-accuracy-deep-learning-feature-extraction-practice-programming-exercise/>
 63. 第4回 深層学習による画像分類 - 東京システム技研, 4月 24, 2025にアクセス、
<https://www.tsl.co.jp/ai-seminar-contents-04/>
 64. ニューラルネットワークを使った画像分類(VGG16)の基本的な手順を解説する - Qiita, 4月 24, 2025にアクセス、<https://qiita.com/ykoji/items/e9c2c5d7288c6290d21b>
 65. PyTorch を使用して画像分類モデルをトレーニングする | Microsoft Learn, 4月 24, 2025にアクセス、
<https://learn.microsoft.com/ja-jp/windows/ai/windows-ml/tutorials/pytorch-train-model>
 66. カスタムデータセットでなるべくかんたんに画像分類器をつくりたい。Pytorchで転移学習 - Qiita, 4月 24, 2025にアクセス、
<https://qiita.com/john-rocky/items/e386f0aa5232d323db7e>
 67. チュートリアル: 画像をカテゴリー分けするためのML.NET分類モデル - Learn Microsoft, 4月 24, 2025にアクセス、
<https://learn.microsoft.com/ja-jp/dotnet/machine-learning/tutorials/image-classification>
 68. 画像分類器を再トレーニングする | TensorFlow Hub, 4月 24, 2025にアクセス、
https://www.tensorflow.org/hub/tutorials/tf2_image_retraining?hl=ja
 69. qiita.com, 4月 24, 2025にアクセス、
https://qiita.com/kouta_hara/items/c196f138830d02355ce8#:~:text=%E7%94%BB%E5%83%8F%E5%88%86%E9%A1%9E%E3%81%A7%E3%81%AF%E3%80%81%E3%81%BE%E3%81%9A%E7%94%BB%E5%83%8F,%E8%87%AA%E5%8B%95%E7%89%B9%E5%BE%B4%E9%87%8F%EF%BC%89%E3%81%8C%E3%81%82%E3%82%8A%E3%81%BE%E3%81%99%E3%80%82
 70. 分類モデルの性能評価と精度指標の基礎 | miLab - MI-6, 4月 24, 2025にアクセス、
<https://mi-6.co.jp/milab/article/t0017/>
 71. 【初心者向け】Pythonを使ってディープラーニングによる画像分類を体験してみよう！ -

- AI Academy, 4月 24, 2025にアクセス、<https://aiacademy.jp/media/?p=113>
72. 深層学習入門: 画像分類モデルを作ろう(3) ～前編～ | SBテクノロジー (SBT), 4月 24, 2025にアクセス、
https://www.softbanktech.co.jp/special/blog/cloud_blog/2019/0046/
73. 画像分類のための精度評価 - ArcMap Resources for ArcGIS Desktop, 4月 24, 2025にアクセス、
<https://desktop.arcgis.com/ja/arcmap/latest/manage-data/raster-and-images/accuracy-assessment-for-image-classification.htm>
74. 精度評価—ArcGIS Pro | ドキュメント, 4月 24, 2025にアクセス、
<https://pro.arcgis.com/ja/pro-app/latest/help/analysis/image-analyst/accuracy-assessment.htm>
75. 【機械学習モデル】評価方法とモデル評価の指標をくわしく解説 - Rabiloo (ラビロー), 4月 24, 2025にアクセス、<https://rabiloo.co.jp/blog/model-evaluation>
76. Python画像分類(評価指標コードまとめ) | AI black brain - note, 4月 24, 2025にアクセス、https://note.com/ai_frontier/n/nc924dd765299
77. AIで画像を認識・分類・予測！機械学習や深層学習で需要予測 - AIポータルメディア Alsmiley, 4月 24, 2025にアクセス、
https://aismiley.co.jp/ai_news/what-are-machine-learning-and-deep-learning-the-t-classify-images-and-forecast-demand/
78. 画像データに対するモデル予測の説明 | Google Cloud 公式ブログ, 4月 24, 2025にアクセス、
<https://cloud.google.com/blog/ja/products/ai-machine-learning/explaining-model-predictions-on-image-data>
79. 初心者向け画像処理完全ガイド | 基礎から主要技術・キャリアパス・学習方法まで徹底解説, 4月 24, 2025にアクセス、
<https://tech-education-nav.com/learn/development-category/about-image-processing>
80. 【初心者向け】画像処理 | 領域分割と特徴抽出の基本を徹底解説 - Hakky Handbook, 4月 24, 2025にアクセス、
<https://book.st-hakky.com/data-science/image-processing-region-segmentation/>
81. 画像の特徴量抽出とは？主要6つのアルゴリズムわかりやすく解説！ - Tech Teacher, 4月 24, 2025にアクセス、
<https://www.tech-teacher.jp/blog/image-feature-extraction/>
82. 少ない画像から画像分類を学習させる方法(kerasで転移学習: fine tuning) - SPJ, 4月 24, 2025にアクセス、<https://spjai.com/keras-fine-tuning/>
83. 【2025】CNNと画像分類の6つの代表的なアーキテクチャの特徴まとめ - AI研究所, 4月 24, 2025にアクセス、
<https://ai-kenkyujo.com/artificial-intelligence/ai-architecture-02/>
84. 機械学習とCNNの関係とは？仕組みや特徴・活用例を分かりやすく解説 - TRYETING, 4月 24, 2025にアクセス、<https://www.tryeting.jp/column/6068/>
85. CNNとは？ディープラーニングの基礎知識を解説 - Creative Drive, 4月 24, 2025にアクセス、<https://creative-drive.jp/column/450/>
86. 画像認識でよく聞く「CNN」とは？仕組みや特徴を1から解説 - Alsmiley, 4月 24, 2025にアクセス、https://aismiley.co.jp/ai_news/cnn/

87. CNN(畳み込みニューラルネットワーク)とは？ わかりやすく解説, 4月 24, 2025にアクセス、<https://www.hitachi-solutions-create.co.jp/column/technology/cnn.html>
88. 最先端の画像認識技術の仕組み・活用事例を紹介 - Aidiotプラス, 4月 24, 2025にアクセス、https://aidiot.jp/media/ai/image_recognition_cutting_edge/
89. 画像認識技術で実現できること・活用事例を紹介 - Aidiotプラス, 4月 24, 2025にアクセス、https://aidiot.jp/media/ai/image_recognition_can/
90. 【最新】画像認識AIの導入活用事例10選！ 各業界企業の課題と導入効果まとめ - Alsmiley, 4月 24, 2025にアクセス、https://aismiley.co.jp/ai_news/image-recognition-case-study-matome/
91. AIによる画像認識の導入活用事例16選を徹底解説 - AI Market, 4月 24, 2025にアクセス、https://ai-market.jp/technology/ai_gazouninshiki/
92. 画像解析の基礎知識。AIを使うメリット・デメリットを紹介 - 株式会社シルク・ラボラトリ, 4月 24, 2025にアクセス、<https://www.silk.co.jp/column/image-analysis/>
93. 画像認識・分類技術による製品管理・分類業務の自動化事例 | NTTデータ数理システム - MSIISM, 4月 24, 2025にアクセス、<https://www.msiism.jp/article/nttdata-image-classification.html>
94. たったの20分で誰でも画像分類の実装ができる方法をわかりやすく解説 - YouTube, 4月 24, 2025にアクセス、<https://m.youtube.com/watch?v=VMH05DbIzvg&pp=ygUNI-eUu-WDj-WIhumhng%3D%3D>